VV-F – VECNÝ ZÁMER PROJEKTU

Záväzná osnova pre aplikovaný výskum a vývoj (VV 2024)

Predbežná verzia, Metódy inžinierskej práce, ak. rok 2026/27

Názov projektu	Inteligentný systém na automatizované testovanie bezpečnosti webových aplikácií pomocou veľkých jazykových modelov (AI-PENTEST)
Zodpovedný riešiteľ	Andrii Tsybulskyi
Riešitelia	Kyrylo Bukhanets, Artur Toba, Maksym Tomkevych
Žiadateľ	Slovenská technická univerzita v Bratislave, Fakulta informatiky a informačných technológií
Štatutárny zástupca žiadateľa	[rektor/ka STU]

1 Excelentnosť

Projektový zámer, navrhovaný spôsob riešenia a aplikačná úroveň očakávaných výsledkov

Penetračné testovanie webových aplikácií je dnes prevažne manuálna a drahá činnosť. Automatizované skenery sú rýchle, no zraniteľnosti viazané na logiku a stav aplikácie často prehliadnu [2]. Veľké jazykové modely (LLM) a agentné systémy postavené nad nimi ukazujú, že dokážu plánovať test, ovládať bežné nástroje a v niektorých prípadoch samostatne zneužiť zraniteľnosť [1, 3]. Chýba však spoločné, bezpečné a opakovateľné prostredie, v ktorom by sa schopnosti takýchto agentov dali objektívne porovnať.

Projekt AI-PENTEST preto vytvorí **Web Pentest Harness** – kontrolované prostredie, v ktorom AI agent dostane prístup k zámerne zraniteľnej webovej aplikácii a pokúsi sa ju samostatne otestovať. Harness:

- spúšťa testované aplikácie v izolovaných kontajneroch bez prístupu na internet,
- poskytuje agentovi jednotnú sadu nástrojov (HTTP klient, prehliadač, skener, terminál v sandboxe),
- zaznamenáva každú akciu agenta a pred jej vykonaním kontroluje povolený rozsah,
- overuje nahlásené zraniteľnosti kontrolovaným proof-of-concept postupom,
- porovnáva nálezy s referenčnou databázou a počíta hodnotiace metriky.

Očakávané výsledky sú na úrovni overenia technológie v relevantnom prostredí (TRL 5): funkčný softvér, verejný benchmark a metodika hodnotenia, ktoré môžu priamo použiť výskumné tímy, bezpečnostné firmy aj vyučujúci.

Aktuálnosť cieľov a originalita projektu

Bezpečnosť webových aplikácií zostáva kritickou oblasťou – kategórie OWASP Top 10 sa v praxi opakovane objavujú [6]. Súčasne prudko rastú schopnosti AI agentov a s nimi aj potreba merať ich prínos aj riziká, čo zdôrazňujú aj odporúčania NIST pre hodnotenie AI systémov [4, 5].

Originalita projektu spočíva v troch bodoch: (1) harness hodnotí nielen to, *či* agent uspel, ale aj *ako* – presnosť, úplnosť, falošné nálezy, čas a náklady; (2) každý nález sa automaticky overuje, takže výsledky nezávisia od tvrdení samotného modelu; (3) benchmark obsahuje aj vlastné, nepublikované zraniteľnosti, čím sa obmedzí skreslenie spôsobené tým, že model mohol verejné úlohy vidieť pri trénovaní. Existujúce benchmarky typu *capture the flag*, napríklad Cybench [10], sa sústreďujú na nájdenie vlajky, nie na úplnosť nálezov v reálnej webovej aplikácii.

Stav poznania, vedecké základy a predchádzajúce výsledky

Metodickým základom testovania je OWASP Web Security Testing Guide [8]. Klasické nástroje statickej (SAST) a dynamickej (DAST) analýzy, napríklad ZAP [9], poskytujú rýchlu, no plytkú kontrolu. Prvé práce s LLM ukázali, že modely zvládajú jednotlivé kroky penetračného testu, no strácajú kontext pri dlhých úlohách; PentestGPT to rieši rozdelením na moduly uvažovania, generovania a spracovania výstupov [1]. Autonómni agenti dokázali v izolovanom prostredí zneužiť viaceré typy webových zraniteľností [3]. Ako cieľové aplikácie sa bežne používajú zámerne zraniteľné systémy, napríklad OWASP WebGoat [7]. Podrobný prehľad je obsahom sprievodného prehľadového článku.

Ciele projektu a reálnosť ich dosiahnutia

C1 – Harness. Navrhnúť a implementovať Web Pentest Harness s izoláciou, záznamom akcií a kontrolou rozsahu. *Ukazovateľ:* 100 % akcií agenta zaznamenaných, 0 únikov mimo izolovanej siete počas experimentov.

C2 – Benchmark. Vytvoriť aspoň 40 úloh v minimálne 8 triedach zraniteľností s anotovanou referenčnou databázou; aspoň 25 % úloh bude nepublikovaných.

C3 – Hodnotenie. Implementovať hodnotiaci modul s metrikami presnosť P, úplnosť R, F_1, miera falošných nálezov, medián času do nálezu a cena behu.

C4 – Porovnanie. Porovnať aspoň 4 architektúry agentov a 3 jazykové modely s klasickým DAST nástrojom; každú konfiguráciu spustiť aspoň 5-krát.

Ciele sú reálne: využívajú existujúce otvorené technológie (kontajnery, zraniteľné aplikácie, API modelov) a tím ich overí najprv na pilotnej verzii s niekoľkými úlohami.

Metodológia riešenia a jej opodstatnenosť

Riešenie postupuje iteratívne. V každej iterácii sa rozšíri benchmark, spustia sa experimenty a podľa výsledkov sa upraví harness.

1. **Návrh architektúry.** Oddelenie agenta, nástrojov, testovanej aplikácie a hodnotiaceho modulu, aby sa dali vymieňať nezávisle.
2. **Tvorba úloh.** Každá úloha obsahuje kontajner s aplikáciou, zoznam zraniteľností (typ, URL, parameter, závažnosť) a skript na overenie.
3. **Experimenty.** Agent dostane iba URL a popis rozsahu. Harness zaznamená priebeh a výsledné nálezy.
4. **Vyhodnotenie.** Nález je správny (TP), ak sa zhoduje s referenčnou zraniteľnosťou v type aj umiestnení. Z počtov TP, FP a FN sa vypočíta

$$P = \frac{TP}{TP + FP}, \qquad R = \frac{TP}{TP + FN}, \qquad F_1 = \frac{2PR}{P + R}.$$

   Výsledky sa uvádzajú ako priemer a smerodajná odchýlka cez opakované behy.

Zvolený postup je opodstatnený, pretože jediný spoľahlivý spôsob, ako porovnať nedeterministické systémy, je opakované meranie na rovnakých úlohách s nezávislým overením výsledku.

Najdôležitejšie výstupy zodpovedného riešiteľa za posledných 5 rokov

Zodpovedný riešiteľ je mladý výskumný pracovník na začiatku kariéry a zatiaľ nemá aplikačné výstupy. [doplniť prípadné študentské projekty, súťaže alebo publikácie]

Najdôležitejšie projekty zodpovedného riešiteľa za posledných 5 rokov

Žiadne. Projekt je prvým samostatným projektom tímu.

Kvalita zodpovedného riešiteľa, expertíza a vízia

Zodpovedný riešiteľ sa venuje bezpečnosti webových aplikácií a využitiu jazykových modelov. Víziou je vybudovať na FIIT STU tím, ktorý bude udržiavať otvorený benchmark a rozvíjať ho aj po skončení projektu, napríklad v rámci diplomových prác.

Kompetentnosť zúčastnených organizácií

FIIT STU má dlhodobé skúsenosti s výskumom a výučbou v oblasti informačnej bezpečnosti a umelej inteligencie a disponuje výpočtovou infraštruktúrou na spúšťanie kontajnerizovaných experimentov.

Expertíza jednotlivých riešiteľov

- **Kyrylo Bukhanets** – klasické nástroje SAST/DAST, porovnávacie experimenty.
- **Artur Toba** – integrácia jazykových modelov a návrh architektúr agentov.
- **Maksym Tomkevych** – tvorba zraniteľných aplikácií, referenčná databáza, bezpečnosť a etika experimentov.

Zapojenie mladých pracovníkov do 35 rokov

Všetci štyria riešitelia sú mladí pracovníci do 35 rokov, čo predstavuje 100 % riešiteľskej kapacity. Projekt je zároveň príležitosťou na vznik bakalárskych a diplomových prác.

2 Dopad

Prínosy pre rozvoj poznania, aplikovaného výskumu a inovácií

- nová technológia: otvorený Web Pentest Harness na bezpečné testovanie AI agentov,
- nová dátová sada: benchmark webových zraniteľností s overiteľnou referenčnou databázou,
- nový postup: metodika hodnotenia AI agentov v bezpečnostnom testovaní,
- nové poznatky: empirické porovnanie agentov vrátane typických zlyhaní.

Spôsob a miera využiteľnosti výsledkov v SR a v zahraničí

Žiadateľ využije harness vo výučbe predmetov zameraných na bezpečnosť a ako platformu pre ďalší výskum. Bezpečnostné firmy a CSIRT tímy ho môžu použiť na nezávislé porovnanie komerčných AI nástrojov pred ich nasadením. Keďže výstupy budú otvorené a v angličtine, sú priamo použiteľné aj v zahraničí.

Ekonomický a spoločenský prínos

Lepšie hodnotenie AI nástrojov znižuje riziko, že organizácie nasadia nástroj, ktorý vytvára falošný pocit bezpečia. Automatizácia častí testovania môže znížiť náklady na bezpečnostné audity malých a stredných podnikov. Projekt zároveň zvyšuje kvalitu ľudských zdrojov – pripravuje odborníkov v oblasti, kde je na trhu výrazný nedostatok.

Opatrenia na maximalizáciu výsledkov a komunikácia

- zverejnenie zdrojového kódu a benchmarku pod otvorenou licenciou,
- publikácia výsledkov na medzinárodnej konferencii a v časopise,
- verejná tabuľka výsledkov (leaderboard) pre nové modely,
- workshop pre študentov a odbornú verejnosť na FIIT STU,
- zodpovedné zverejňovanie: bez návodov na útok na reálne systémy.

3 Implementácia

Projektový plán, pracovné balíky, míľniky a výstupy

Balík	Obsah	Obdobie	Zodpovedný
PB1	Analýza stavu poznania, požiadavky, architektúra harness	07/2027–12/2027	A. Tsybulskyi
PB2	Zraniteľné aplikácie a referenčná databáza	01/2028–12/2028	M. Tomkevych
PB3	Implementácia harness a integrácia agentov	01/2028–12/2028	A. Toba
PB4	Experimenty a porovnanie s klasickými nástrojmi	01/2029–12/2029	K. Bukhanets
PB5	Vyhodnotenie, diseminácia, riadenie projektu	07/2027–06/2030	A. Tsybulskyi

Míľniky: M1 (12/2027) schválená architektúra a taxonómia úloh; M2 (06/2028) pilotná verzia harness s 10 úlohami; M3 (12/2028) kompletný benchmark so 40 úlohami; M4 (12/2029) ukončené experimenty a dátová sada výsledkov; M5 (06/2030) otvorené vydanie a záverečná správa.

Projektový manažment

Tím pracuje agilne v dvojtýždňových šprintoch evidovaných v nástroji Jira; zdrojové kódy a dokumenty sú v spoločnom Git repozitári a každá zmena je prepojená s úlohou. Zodpovedný riešiteľ raz mesačne kontroluje plnenie míľnikov a rozpočtu.

Riziká implementácie a ich zmiernenie

Riziko	Zmiernenie
Únik agenta mimo testovacieho prostredia	sieťová izolácia, kontrola rozsahu pred každou akciou, zakázané deštruktívne operácie
Zmena alebo ukončenie dostupnosti komerčných modelov	zaznamenanie verzie modelu, využitie aj otvorených modelov
Kontaminácia benchmarku trénovacími dátami	podiel vlastných nepublikovaných úloh
Prekročenie nákladov na API modelov	limity tokenov na beh, priebežné sledovanie nákladov

Adekvátnosť rozpočtu

Najväčšiu časť rozpočtu (163 200 EUR vrátane poistného) tvoria osobné náklady štyroch riešiteľov a technickej podpory. Položka služieb (24 000 EUR) pokrýva cloudový výpočtový výkon a prístup k API jazykových modelov, ktoré sú pre experimenty nevyhnutné. Cestovné (9 000 EUR) a popularizácia (3 000 EUR) slúžia na prezentáciu výsledkov. Nákup prístrojov sa neplánuje.

Existujúca technická a personálna infraštruktúra

FIIT STU poskytuje výpočtové servery, sieťovú infraštruktúru umožňujúcu izolované experimenty a laboratórium informačnej bezpečnosti. Personálne kapacity tvoria štyria riešitelia a jeden technický pracovník.

Literatúra

[1] Gelei Deng, Yi Liu, Víctor Mayoral-Vilches, Peng Liu, Yuekang Li, Yuan Xu, Tianwei Zhang, Yang Liu, Martin Pinzger, and Stefan Rass. PentestGPT: Evaluating and harnessing large language models for automated penetration testing. In *33rd USENIX Security Symposium (USENIX Security 24)*, pages 847–864, 2024.

[2] Adam Doupé, Marco Cova, and Giovanni Vigna. Why Johnny can't pentest: An analysis of black-box web vulnerability scanners. In *Detection of Intrusions and Malware, and Vulnerability Assessment (DIMVA 2010)*, volume 6201 of *Lecture Notes in Computer Science*, pages 111–131. Springer, 2010.

[3] Richard Fang, Rohan Bindu, Akul Gupta, Qiusi Zhan, and Daniel Kang. LLM agents can autonomously hack websites. arXiv:2402.06664, 2024.

[4] T. Jensen, M. Przybocki, M. Kodwani, K. Greene, P. Hall, R. Amironesei, and C. Greenberg. Aria evaluation planning manual: Elements of aria-style ai evaluations. Technical Report NIST AI 200-3, National Institute of Standards and Technology, 2026.

[5] National Institute of Standards and Technology. Ai measurement and evaluation. `https://www.nist.gov/ai-measurement-and-evaluation`, 2024. Online; citované 11. 10. 2026.

[6] OWASP Foundation. Owasp top 10: The ten most critical web application security risks. `https://owasp.org/www-project-top-ten/`. Online; citované 11. 10. 2026.

[7] OWASP Foundation. Owasp webgoat. `https://owasp.org/www-project-webgoat/`. Online; citované 11. 10. 2026.

[8] OWASP Foundation. Web security testing guide. `https://owasp.org/www-project-web-security-testing-guide/`, 2020. Online; citované 11. 10. 2026.

[9] ZAP Development Team. ZAP – zed attack proxy. `https://www.zaproxy.org/`. Online; citované 1. 11. 2026.

[10] Andy K. Zhang et al. Cybench: A framework for evaluating cybersecurity capabilities and risks of language models. arXiv:2408.08926, 2024.