Inteligentný systém na automatizované testovanie bezpečnosti webových aplikácií pomocou veľkých jazykových modelov

Využitie veľkých jazykových modelov a AI agentov na automatizované bezpečnostné testovanie webových aplikácií.

AI-PENTEST

Kyrylo Bukhanets, Artur Toba, Maksym Tomkevych , Andrii Tsybulskyi
FIIT STU
bukhanets@stuba.sk, xtoba@stuba.sk , xtomkevych@stuba.sk , xtribulskyi@stuba.sk
4. 10. 2026

Smer (oblasť výskumu)

Aplikovaný výskum v oblasti umelej inteligencie a kybernetickej bezpečnosti.

Čo presne budeme robiť

Cieľom nie je iba to, že „neurónová sieť hľadá hackerské zraniteľnosti“. Vytvárame **Web Pentest Harness** – špecializované prostredie, v ktorom AI agent dostane webovú aplikáciu a pokúsi sa samostatne vykonať jej kontrolované bezpečnostné testovanie.

Princíp:

Webová aplikácia → AI agent → Pentest Harness → testy → zistené zraniteľnosti → automatické vyhodnotenie

Harness bude:

- poskytovať AI agentovi bezpečné testovacie prostredie;
- poskytovať mu nástroje na interakciu s webovou aplikáciou;
- zaznamenávať všetky akcie modelu;
- overovať, či nájdená zraniteľnosť skutočne existuje;
- hodnotiť úspešnosť agenta;
- zbierať výsledky na následné porovnanie rôznych AI modelov.

Prečo je to dobrá téma

Ide o konkrétny inžiniersky problém: súčasné jazykové modely dokážu vykonávať zložité úlohy súvisiace s analýzou webových aplikácií, no chýba vhodné štandardizované prostredie na bezpečné a objektívne porovnávanie ich schopností v oblasti penetračného testovania. Navrhovaným riešením je práve vytvorenie Web Pentest Harness, ktorý umožní štandardizovane testovať a hodnotiť AI agentov na kontrolovaných webových zraniteľnostiach – ide teda o skutočný aplikovaný výskum, nie len o „neurónovú sieť na hľadanie hackerských dier".

Anotácia

Súčasné veľké jazykové modely dokážu vykonávať zložité úlohy súvisiace s analýzou webových aplikácií, no v súčasnosti chýba vhodné štandardizované prostredie na bezpečné a objektívne porovnávanie ich schopností v oblasti penetračného testovania. Projekt AI-PENTEST preto navrhuje vytvoriť Web Pentest Harness – kontrolované prostredie, v ktorom AI agent dostane webovú aplikáciu a pokúsi sa samostatne vykonať jej bezpečnostné testovanie. Harness poskytuje agentovi bezpečné testovacie prostredie aj nástroje na interakciu s aplikáciou, zaznamenáva všetky jeho akcie, overuje, či nájdená zraniteľnosť skutočne existuje (prostredníctvom kontrolovaného proof-of-concept overenia), vyhodnocuje úspešnosť agenta a zbiera výsledky na následné porovnanie viacerých AI modelov. Jadrom riešenia je kontajnerizovaná sada zámerne zraniteľných webových aplikácií so známymi triedami chýb (SQL injection, XSS, autentifikačné a autorizačné obchádzky, SSRF, IDOR, nesprávna konfigurácia a pod.), doplnená anotovanou databázou referenčných zraniteľností (ground truth) a automatizovaným hodnotiacim modulom počítajúcim metriky ako presnosť, úplnosť (recall), mieru falošne pozitívnych nálezov a čas potrebný na nájdenie a overenie zraniteľnosti. Agent pracuje výlučne v sieťovo izolovanom prostredí s riadenými povoleniami, čo umožňuje bezpečné a reprodukovateľné experimenty. Výstupom projektu bude otvorená infraštruktúra (harness + benchmark sada úloh rôznej obtiažnosti) a empirické porovnanie viacerých architektúr AI agentov z hľadiska efektivity, spoľahlivosti a typických zlyhaní. Projekt tak prispieva k zodpovednému a štandardizovanému hodnoteniu kybernetických schopností AI systémov.

Právne zdroje

1. OWASP Foundation. *Web Security Testing Guide v 4.2.* 2020.
   `https://owasp.org/www-project-web-security-testing-guide/`
2. OWASP Foundation. *The OWASP Web Security Testing Framework.* 2020.
   `https://wstg.owasp.org/stable/3-The_OWASP_Testing_Framework/0-The_Web_Security_Testing_Framework/`
3. OWASP Foundation. *OWASP WebGoat.*
   `https://owasp.org/www-project-webgoat/`
4. National Institute of Standards and Technology. *AI Measurement and Evaluation.* 2024.
   `https://www.nist.gov/ai-measurement-and-evaluation`
5. National Institute of Standards and Technology. *Building Evaluation Probes into Agentic AI.* 2026.
   `https://www.nist.gov/programs-projects/building-evaluation-probes-agentic-ai`
6. Jensen, T., Przybocki, M., Kodwani, M., Greene, K., Hall, P., Amironesei, R., Greenberg, C. *ARIA Evaluation Planning Manual: Elements of ARIA-Style AI Evaluations.* NIST AI

200-3. 2026.
https://doi.org/10.6028/NIST.AI.200-3